RESEARCH METHODOLOGY PASSPORT • TASK 2

Карточка методологии исследования

Сравнительный анализ алгоритмов машинного обучения (Random Forest vs LightGBM) для детекции аномалий и DDoS-атак в реальном времени в ресурсоограниченных сетях IoT

Автор: Балкыбек Бауыржан (индивидуальное выполнение)

Дисциплина: Методы научных исследований (IT)

GitHub-репозиторий: https://github.com/Bauyrjan18/Method

Целевой бенчмарк: CICIoT2023 Dataset

1. Тип исследования и обоснование

Тип исследования: Количественное экспериментальное исследование (Quantitative Experimental Research).
Обоснование выбора: Исследование направлено на объективную верификацию гипотез посредством контролируемого вычислительного эксперимента. Измеряются строго количественные зависимые переменные: метрики качества классификации (Macro F1-score, Precision, Recall), временные характеристики (Inference Latency в мс) и системные ресурсы (RAM в МБ). Качественные методы не обеспечивают статистической строгости при оценке компромисса (trade-off) между точностью и микросекундной задержкой инференса сетевых пакетов на периферийных IoT-шлюзах.

2. Формулировка гипотез

Исследовательский вопрос 1 (RQ1 — Точность классификации)

> **Нулевая гипотеза ($H_{0,1}$):** При классификации аномалий и DDoS-трафика алгоритм LightGBM не демонстрирует статистически значимого превосходства по F1-score по сравнению с Random Forest ($F1_{LightGBM} \leq F1_{RandomForest}$).
>
> **Альтернативная гипотеза ($H_{1,1}$):** Алгоритм гистограммного бустинга LightGBM обеспечивает статистически значимо более высокий Macro F1-score по сравнению с Random Forest при обработке атак высокой интенсивности ($F1_{LightGBM} > F1_{RandomForest}$), достигая F1 ≥ 0.95.

Исследовательский вопрос 2 (RQ2 — Редукция признаков и ресурсоэффективность)

> **Нулевая гипотеза ($H_{0,2}$):** Редукция признакового пространства до топ-10 признаков не приводит к снижению задержки инференса на пакет и потребления RAM в LightGBM более эффективно, чем в Random Forest, либо вызывает недопустимую деградацию качества (F1 < 0.95).
>
> **Альтернативная гипотеза ($H_{1,2}$):** Сокращение пространства признаков до топ-10 уменьшает задержку инференса более чем на 30% и сокращает потребление RAM более чем на 25% в LightGBM по сравнению с Random Forest при сохранении порогового уровня F1 ≥ 0.95.

3. Матрица переменных эксперимента

Категория	Переменная	Значения / Ед. изм.	Роль и операционализация
Независимая	ML-классификатор	RandomForest, LightGBM	Варьируемый класс ансамблевых алгоритмов (бэггинг vs градиентный бустинг).
Независимая	Размерность признаков	Full (46 фичей), Top-10	Варьируемый состав входного вектора потока для проверки гипотезы оптимизации.
Независимая	Размер батча инференса	N ∈ {1, 16}	Поштучный потоковый анализ пакетов (N=1) и микро-очереди (N=16).
Зависимая	Macro F1-Score	[0.0000, 1.0000]	Первичная метрика сбалансированной детекции

Категория	Переменная	Значения / Ед. изм.	Роль и операционализация
			классов сетевых аномалий.
Зависимая	Inference Latency	миллисекунды (мс) / образец	Среднее время и P99 принятия решения моделью по сетевому пакету.
Зависимая	Потребление RAM (RSS)	Мегабайты (МБ)	Резидентная память процесса и пиковый объем динамической памяти.
Зависимая	Throughput	образцов / сек	Пропускная способность конвейера классификации.
Контролируемая	Входной датасет	CICIoT2023	Фиксированный эталонный бенчмарк трафика IoT.
Контролируемая	Разбиение данных	Train/Test 80/20, Seed=42	Идентичные выборки для обучения и валидации всех моделей.
Контролируемая	Окружение	Docker, Python 3.12	Строго зафиксированные версии библиотек (pinned dependencies).

4. Метрики, Пороговые ограничения (Guardrails) и Baseline

- **Первичная метрика (Primary Metric):** Macro F1-score (устойчивость детекции при дисбалансе классов) и Inference Latency на 1 образец (мс).
- **Пороговые метрики (Guardrail Metrics):**
  - Минимальное качество классификации: **F1 ≥ 0.95** (недопустимость пропуска атак).
  - Максимальный лимит оперативной памяти: **Peak RAM ≤ 256.0 МБ** (аппаратное ограничение edge-устройств).
  - Максимальная задержка на пакет: **Latency ≤ 15.0 мс** (предотвращение переполнения сетевых очередей).
  - Надежность конвейера: **0% сбоев** (отсутствие необработанных исключений).
- **Контрольная группа / Бэйзлайн (Baseline):** Классический ансамбль **Random Forest (RF)** на **полном наборе признаков (Full Feature Set — 46 признаков)** со стандартной конфигурацией (`n_estimators=100`, `max_depth=15`). Выступает общепринятым индустриальным эталоном точности и стабильности в IDS.